


Prédiction de Maladie Cardiaque

Projet Machine Learning End-to-End — De la donnée clinique à l'aide au diagnostic

918 patients • 11 variables cliniques • 2 classes (Sain / Malade)

Améni Dhaouadi



Heart Disease Dataset

Source & Contexte

Stanford University – 918 patients avec données cliniques complètes

Dataset largement utilisé sur Kaggle pour la recherche en diagnostic assisté par l'IA



les 4 familles des variables:

Données démographiques

Age, Sex

Marqueurs physiologiques

RestingBP, Cholesterol

Réponse à l'effort

MaxHR, Oldpeak

Indicateurs ECG

ChestPainType, ST_Slope

Cible : HeartDisease – 0 = Sain, 1 = Malade

6 visualisations – Résultats clés

1

Matrice de Corrélation

Oldpeak (+0.42) et MaxHR (-0.38) sont les plus corrélés avec la cible

2

Top Features vs HeartDisease

Oldpeak, ST_Slope_Flat, ChestPainType_ASY en tête

3

KDE Distributions

Oldpeak : distribution décalée entre sains et malades

4

Boxplots – Outliers

Quelques outliers sur Cholesterol (valeurs à 0 conservées)

5

Pairplot (4 features clés)

Oldpeak, MaxHR, Age, Cholesterol – séparabilité visuelle

6

PCA 2 composantes

Projection 2D – clusters bien distincts

3 modèles comparés

Modèle	Paramètres	Accuracy	ROC AUC	F1-Score
Régression Logistique	max_iter=1000	85.3%	0.91	0.86
Random Forest	n_estimators=100, rs=42	87.0%	0.92	0.87
XGBoost	n_estimators=200, max_depth=6, lr=0.1	89.1%	0.94	0.89


Modèle sélectionné : XGBoost optimisé (F1-Score = 89%, AUC = 94%)

Modèle retenu : XGBoost optimisé

Matrice de Confusion

Test set (184 patients)

	Prédit Sain	Malade
Vérité Sain (0)	73	5
Malade (1)	11	95



Comparatif final

Modèle	Accuracy	AUC ROC	F1-Score
Régression Logistique	85.3%	0.91	0.86
Random Forest	87.0%	0.92	0.87
XGBoost	89.1%	0.94	0.89

✅ **XGBoost sélectionné** : meilleur F1-Score (89%), AUC le plus élevé (94%), faux négatifs minimisés (11 seulement)

Top 3 features – Importance (XGBoost)

24%

Oldpeak (dépression ST)

Indicateur ECG crucial de la dépression du segment ST lors de l'effort

18%

ST_Slope_Flat

Caractéristique morphologique de l'électrocardiogramme liée au risque

15%

**ChestPainType_ASY
(angine atypique)**

Type de douleur thoracique associé à un profil symptomatique à risque

FEATURE IMPORTANCE



📌 Ces 3 features expliquent près de 60% du pouvoir prédictif du modèle.

Bilan du projet

01

Dataset

918 patients, 11 features, 0 NaN, classes équilibrées (54.8% / 45.2%)

02

EDA

6 visualisations : corrélations, top features, KDE, boxplots, pairplot, PCA – séparabilité confirmée

03

Prétraitement

One-Hot Encoding + StandardScaler + split stratifié (80/20)

04


Modèle retenu

XGBoost optimisé – F1-Score = 89%, AUC ROC = 94%

05

Résultats

164/184 patients bien classés, **11 faux négatifs seulement**



Conclusion & Perspectives

Bilan

- F1-Score = **0.89** – objectif technique atteint
- AUC ROC = **0.94** – excellente discrimination
- **11 faux négatifs** sur 184 patients testés
- Modèle validé sur données jamais vues

Perspectives

- Collecter davantage de données (actuellement 918 lignes)
- Tester des architectures **Deep Learning**
- **Déployer via API** (Flask / FastAPI) avec interface Streamlit
- Valider sur un **dataset externe indépendant**

Merci de votre attention !

Des questions ?

