

Prédiction de Maladie Cardiaque

Projet Machine Learning End-to-End — De la donnée clinique à l'aide au diagnostic

AMENI DHAOUADI



Plan de la présentation

Six étapes structurées pour comprendre notre démarche complète, de la problématique médicale aux résultats du modèle.

01

Contexte & Objectifs

Enjeux sanitaires et cadrage du projet

02

Dataset & Analyse Exploratoire

Exploration et visualisation des données

03

Prétraitement des données

Nettoyage, encodage et standardisation

04

Modélisation & Optimisation

Trois algorithmes comparés et optimisés

05


Résultats & Interprétation

Performances, matrice et importance des features

06

Conclusion & Perspectives

Bilan du projet et pistes d'amélioration



Contexte Médical

17,9M

Décès par an

32% des décès mondiaux sont
d'origine cardiovasculaire

1/3

Personnes à risque

Une personne sur trois
développera une maladie
cardiaque

30-50%

Réduction mortalité

Grâce à un diagnostic précoce et
ciblé

Objectifs du Projet

Objectif Business

Développer un outil d'aide au diagnostic permettant aux cardiologues d'identifier rapidement les patients à risque et de prioriser les examens complémentaires.

Objectif Technique

Construire un modèle de classification avec un **F1-Score > 0,85**, en priorisant la minimisation des faux négatifs.

Métriques d'évaluation

F1-Score

Métrique principale – équilibre précision/rappel

AUC-ROC

Capacité à distinguer patients sains et malades

Matrice de confusion

Analyse fine des types d'erreurs

Dataset — heart.csv



Source & Structure

Dataset **Stanford University** — 918 patients, 11 variables cliniques, classification binaire.

Variables principales

- **Age, Sex** — Données démographiques
- **RestingBP, Cholesterol** — Marqueurs physiologiques
- **MaxHR, Oldpeak** — Réponse à l'effort
- **ChestPainType, ST_Slope** — Indicateurs ECG

i **Cible** : HeartDisease — 0 = Sain, 1 = Malade

Analyse Exploratoire des Données


Distribution de la cible

Dataset légèrement équilibré : **54,8% malades** vs **45,2% sains** — pas de déséquilibre majeur à corriger.

Insights clés

- **Oldpeak** (+0,42) : la dépression ST élevée est le prédicteur le plus fort
- **MaxHR** (-0,38) : une fréquence cardiaque max basse signale un risque accru
- **ChestPainType_ASY** (+0,35) : l'angine atypique est un indicateur majeur

Prétraitement des Données



Le pipeline garantit des données propres, encodées et normalisées. La **stratification** du split préserve la proportion de la cible dans les deux ensembles, assurant une évaluation fiable.



Modélisation & Optimisation

Régression Logistique

Modèle linéaire simple –
baseline interprétable

Random Forest

Ensemble d'arbres – robuste
aux outliers

XGBoost

Gradient boosting – modèle le plus performant

i Optimisation GridSearchCV : validation croisée 5-fold, métrique F1-Score. Meilleurs hyperparamètres XGBoost :
n_estimators=200, max_depth=6, learning_rate=0,1, subsample=0,8.

Résultats Comparatifs

■ F1-Score (%)

■ AUC-ROC (%)

XGBoost optimisé — Meilleur modèle

F1-Score = 89% — objectif atteint 

AUC-ROC = 94% — excellente discrimination

164 patients bien classés sur 184, dont seulement **11 faux négatifs** (patients malades non détectés).

Top 3 Features

1. **Oldpeak** — 24%
2. **ST_Slope_Flat** — 18%
3. **ChestPainType_ASY** — 15%

Conclusion & Perspectives

✓ Bilan du projet

- F1-Score = **0,89** – objectif technique atteint
- Objectifs business et cahier des charges respectés
- Modèle validé sur données de test jamais vues

Applicabilité clinique

Intégration possible dans un système d'aide à la décision pour identifier les patients à risque et réduire les délais de diagnostic.

Perspectives d'amélioration

- Collecter davantage de données (actuellement 918 lignes)
- Tester des architectures Deep Learning
- Déployer via API (Flask / FastAPI) avec interface utilisateur
- Valider sur un dataset externe indépendant

👍 **Merci de votre attention ! Des questions ?**